

Uniwersytet Warszawski
Wydział Matematyki, Informatyki i Mechaniki

Aleksander Mućk

Nr albumu: 382184

Algorytmy do klastrowania duplikacji genomowych

Praca licencjacka
na kierunku BIOINFORMATYKA I BIOLOGIA SYSTEMÓW

Praca wykonana pod kierunkiem
dra hab. Pawła Góreckiego

Sierpień 2019

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data

Podpis kierującego pracą

Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data

Podpis autora pracy

Streszczenie

Niniejsza praca przedstawia propozycje rozwiązań algorytmicznych dla problemów klastrowania duplikacji genomowych w oparciu o scenariusze ewolucyjne. W części pierwszej wprowadzane są podstawowe pojęcia dotyczące drzew genów, gatunków, modeli ich uzgadniania oraz tworzenia scenariuszy ewolucyjnych. Omówiony został również problem przeliczania i klastrowania duplikacji genomowych. W części drugiej opisana została proponowana heurystyka wraz z przykładowymi testami oraz jej implementacją w języku Python.

Słowa kluczowe

duplikacja genu, drzewo genów, drzewo gatunków, analiza filogenetyczna, drzewo uzgadniające, Python, scenariusz ewolucyjny, strata genu, minimalizacja kosztu ewolucyjnego

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.9 Inne nauki matematyczne i informatyczne

Klasyfikacja tematyczna

Computational biology, Applied computing, Life and medical sciences

Tytuł pracy w języku angielskim

Algorithms for the clustering of genomic duplication

Spis Treści

Wprowadzenie	5
1. Podstawowe pojęcia	7
1.1. Wstęp biologiczny	7
1.2. Drzewa genów i gatunków	7
1.3. Uzgodnienie drzew	8
1.3.1. Mapowanie LCA	8
1.3.2. Drzewa DLS	9
1.3.3. Scenariusz LCA	9
1.4. Modele scenariuszy ewolucyjnych	11
1.4.1. Transformacje scenariuszy ewolucyjnych	11
1.4.2. Opis modeli	11
1.5. Koszt scenariuszy ewolucyjnych	13
2. Heurystyka	15
2.1. Opis algorytmu	15
2.2. Dokumentacja użytkowa i opis implementacji	15
2.3. Testy algorytmu	16
2.3.1. Testy algorytmu na danych rzeczywistych	16
2.3.2. Testy algorytmu na danych symulowanych	17
3. Podsumowanie	19
3.1. Perspektywy rozwoju	19
3.2. Perspektywy wykorzystania	19
A. Pętla programu zapisana w języku Python wykonywana dla losowego wybierania indeksów	21
B. Przykładowe drzewa gatunków dla danych syntetycznych	23
C. Przykładowe drzewa genów dla danych syntetycznych	25
Bibliografia	27

Wprowadzenie

Uzgadnianie drzew filogenetycznych jest, przez rozmiar danych i coraz bardziej skomplikowane modele, niezwykle złożone zarówno obliczeniowo jak i koncepcyjnie. Badania drzew genów i gatunków, a w szczególności zależności między nimi może odpowiedzieć na pytania w jaki sposób wyodrębniały się gatunki przez pryzmat zmian w ich genomie. Mimo wszystko jednak należy pamiętać, że pokrewieństwo gatunków nie zawsze implikuje pokrewieństwo genów, których drzewo ewolucyjne nie musi pokrywać się z drzewem zawierającym je gatunków, które samo w sobie nie jest tak bardzo bardzo zróżnicowane jak drzewo genów. Tworzenie scenariuszy ewolucyjnych dzięki którym możemy poznać w jaki sposób ewolucja genów wpływała na ewolucję gatunków jest zadaniem nietrywialnym. Potrzebne są narzędzia, które potrafiłyby ocenić scenariusze pod kątem ilości epizodów ewolucyjnych i przyporządkować je we właściwe miejsca historii ewolucyjnej. Epizody, takie jak duplikacje genomowe, mogą być wyznacznikami prawdopodobieństwa danego scenariusza.

Należy zaznaczyć, że wybranie właściwego scenariusza ewolucyjnego nie jest zadaniem łatwym, ponieważ takich scenariuszy, wyjaśniających ewolucję danej rodziny genów, może być nieskończenie wiele. Problem jeszcze bardziej komplikuje się kiedy w badaniach uwzględnimy wiele takich drzew genów.

W niniejszej pracy proponowany jest algorytm, który ocenia zbiór scenariuszy tworząc na ich podstawie jeden, którego koszt, liczony jako ilość duplikacji, będzie możliwie najmniejszy. Praca składa się z czterech rozdziałów i dodatków. W rozdziale 1 przedstawiono podstawowe pojęcia dotyczące drzew genów, drzew gatunków oraz modeli i scenariuszy ewolucyjnych. Rozdział 2 przedstawia propozycję heurystyki wraz z jej testami na rzeczywistych danych. W rozdziale tym opisano również implementację i sposób użycia programu napisanego na podstawie przybliżonej we wcześniejszej sekcji heurystyki. Ostatni rozdział zawiera przemyślenia dotyczące możliwego użycia algorytmu i perspektyw jego rozwoju. W dodatkach umieszczono fragmenty kodu, przykładowe dane wejściowe i wyniki działania algorytmu.

Rozdział 1

Podstawowe pojęcia

W tym rozdziale poruszane są pojęcia i definicje niezbędne do zrozumienia problematyki klastrowania duplikacji genomowych.

1.1. Wstęp biologiczny

Ewolucja biologiczna jest procesem zmian w trakcie których organizmy stopniowo nabywają lub tracą pewne cechy. Jest to element kluczowy dla powstawania nowych gatunków: specjacji. Śledzenie w jaki sposób kształtowały się nowe gatunki i w jaki sposób zachodziły na Ziemi procesy ewolucyjne jest zadaniem niezwykle złożonym i wymagającym specyficznego podejścia. Jednym z możliwych sposobów przedstawienia historii ewolucyjnej gatunków jest drzewo filogenetyczne, które przedstawiają zależności ewolucyjne pomiędzy umieszczonymi na nim gatunkami lub genami.

Początkowo za wyznacznik pokrewieństwa gatunków służyło podobieństwo morfologiczne, jednak obecnie często stosuje się metody polegające na badaniu podobieństwa danych rodzin genów. Można założyć, że im większe podobieństwo genów danych organizmów tym bliżej są one spokrewnione. Z punktu widzenia tej pracy genom jest niczym więcej jak zbiorem genów obecnym w danym organizmie.

1.2. Drzewa genów i gatunków


W pracy tej T niech będzie ukorzenionym, binarnym drzewem o zbiorze krawędzi E_T i zbiorze węzłów V_T :

$$T = \langle V_T, E_T \rangle.$$


E_T zawiera pary węzłów (v_x, v_y) takie, że $V_T \ni v_x, v_y$. Węzły z których nie wychodzą żadne krawędzie nazywane są liśćmi, a korzeń jest węzłem do którego nie prowadzą żadne krawędzie (nieposiadającym rodzica). Węzeł v_x jest przodkiem węzła v_y jeśli istnieje ścieżka skierowana z węzła v_x do węzła v_y . Liczba krawędzi w ścieżce od węzła v_x do węzła v_y jest nazywana długością. Poddrzewem węzła v_x jest drzewo oznaczone $T(v_x)$ w którym węzeł v_x jest korzeniem. Wszystkie etykiety obecne na liściach widoczne z wierzchołka v_x oznaczymy jako $L(v_x)$.

Definicja 1.2.1 *Związki między gatunkami przedstawia się za pomocą drzewa T , zwanego drzewem gatunków S . W drzewie S każdy z liści reprezentuje inny gatunek Sp , a węzły wewnętrzne są specjacjami. Zbiór wszystkich etykiet oznaczony jest jako $L(S)$.*

Definicja 1.2.2 Związki między genami w danej rodzinie przedstawia się za pomocą drzewa T , zwanego drzewem genów G . W drzewie G każdy z liści reprezentuje przynależność danego genu do gatunku Sp . Zbiór wszystkich etykiet oznaczony jest jako $L(G)$ i $L(G) \subseteq L(S)$.



(a) Przykładowe drzewo genów G



(b) Przykładowe drzewo gatunków S

Rysunek 1.1: Przykładowe drzewa T [1]

1.3. Uzgodnienie drzew


Bardzo częste różnice struktury drzewa genów w stosunku do historii ewolucyjnej opisanej drzewem gatunków wymagają mapowania węzłów drzewa G na węzły znajdujące się w drzewie S . Jest to krok niezbędny by zrozumieć w jaki sposób ewolucja gatunków wpływała na strukturę ich genomów.

1.3.1. Mapowanie LCA

Podstawowym algorytmem dla tego typu uzgodnień jest **algorytm LCA** (ang. *Lowest Common Ancestor*; pl. *Najniższy Wspólny Przodek*). Najniższym przodkiem węzłów v_x i v_y jest taki węzeł v_{anc} , który jest przodkiem obu węzłów i którego długość od korzenia drzewa jest największa. Najniższego wspólnego przodka dwóch węzłów można policzyć w czasie stały po liniowym, jednorazowym preprocesingu drzewa.

Definicja 1.3.1 Mapowanie LCA to funkcja $MAP_{LCA}: G \rightarrow S$ gdzie dla każdego węzła v_g z drzewa genów G $MAP_{LCA}(S)$ to węzeł taki, że:

$$MAP_{LCA}(v_g) = \begin{cases} \text{liść w } S \text{ z tą samą etykietą co } v_g & \text{jeśli } v_g \text{ jest liściem,} \\ MAP_{LCA}(MAP_{LCA}(v_{g_1}), MAP_{LCA}(v_{g_2})) \text{ w } S & \text{jeśli } v_g \text{ ma synów } v_{g_1} \text{ i } v_{g_2}. \end{cases}$$



Rysunek 1.2: Uzgodnienie LCA dla przykładowych drzew genów G i gatunków S

1.3.2. Drzewa DLS

Scenariusz ewolucyjny jest przedstawieniem ewolucji danej rodziny genów, przy uwzględnieniu ewolucji gatunków, które owe geny zawierają. Jako reprezentację scenariusza ewolucyjnego można stosować drzewa T nazwane drzewami DLS (*Duplication-Loss Tree*) [3]. Drzewa te posiadają dwa rodzaje węzłów wewnętrznych i dwa rodzaje liści. Pierwszy rodzaj węzła opisuje zjawisko duplikacji, czyli powielenia tego samego genu do dwóch kopii (oznaczymy jako DUP), zaś drugi jest wyrażeniem zjawiska specjacji (oznaczymy jako SPEC). Pierwszy z rodzajów liści jest opisuje stratę genu (oznaczymy jako LOSS), a drugi jest reprezentacją sekwencji genu obecnego w gatunku o danej etykietce. Drzewo DLS dla ustalonego drzewa genów G i ustalonego drzewa gatunków S , gdzie $L(G) \subseteq L(S)$ definiuje się w następujący sposób:

1. s jest drzewem DLS z jednym węzłem oznaczającym, że sekwencja genu jest obecna w gatunku s ,
2. A - jest drzewem DLS z jednym węzłem oznaczającym epizod straty genu, gdzie A jest niepustym zbiorem gatunków,
3. $(R_1, R_2)^+$ jest drzewem DLS, którego korzeń jest węzłem duplikacyjnym i dzieci korzenia R_1 i R_2 są drzewami DLS takimi, że $L(R_1) = L(R_2)$,
4. $(R_1, R_2)^\sim$ jest drzewem DLS, którego korzeń jest węzłem specjacyjnym i dzieci korzenia R_1 i R_2 są drzewami DLS takimi, że $L(R_1) \cap L(R_2) = \emptyset$.

Należy zaznaczyć, że z każdego drzewa DLS możliwe jest odczytanie drzewa genów za pomocą którego zostało zbudowane drzewo DLS.

1.3.3. Scenariusz LCA


Z wykorzystaniem mapowania LCA węzłów drzewa genów G do drzewa gatunków S można stworzyć drzewo DLS, które reprezentuje scenariusz LCA, to znaczy taki, który zawiera minimalną liczbę duplikacji genomowych potrzebnych do uzgodnienia drzew [?].

Scenariusz LCA dla drzewa G o korzeniu g_r i drzewa S o korzeniu s_r jest drzewem DLS

$p(g_r, MAP_{LCA}(s_r))$, takim, że $p(g, s) = s$ kiedy g i s są liśćmi. W innym przypadku:


$$p(g, s) = \begin{cases} (p(g, u), L(T(v)) -) \sim & \text{jeśli } MAP_{LCA}(g) \in T(u) \\ \quad LOSS & \\ (p(p, u), p(q, v)) \sim & \text{jeśli } MAP_{LCA}(p) \in T(u) \wedge MAP_{LCA}(q) \in T(v) \\ \quad SPEC & \\ (p(p, s), p(q, s)) + & \text{jeśli } MAP_{LCA}(g) = MAP_{LCA}(p) = s \\ \quad DUP & \end{cases}$$

gdzie u i v są dziećmi s a p i q są dziećmi g .



Rysunek 1.3: Drzewo DLS $p(G, S)$ będące scenariuszem LCA zbudowanym w oparciu o mapowanie LCA, które uzgadnia drzewo genów G i drzewo gatunków S z rysunku. Węzeł oznaczony kwadratem jest węzłem duplikacyjnym. Gałęzie narysowane linią przerywaną prowadzą do liści, które są reprezentacją straty genów w danym gatunku.

Przedstawieniem drzewa DLS jest też pewnego rodzaju "wbudowanie" drzewa genów, w kontener będący drzewem gatunków. Przykład tego typu przedstawienia można zobaczyć na rysunku 1.4



Rysunek 1.4: Przykład wbudowania dla drzew z rysunku 1.2.

1.4. Modele scenariuszy ewolucyjnych

Drzewo DLS, które opiera się o mapowanie LCA, jest drzewem o możliwie najmniejszym koszcie ewolucyjnym i możliwe najgłębiej położonych węzłach duplikacyjnych. Nie jest to jednak jedyny możliwy scenariusz, których w rzeczywistości jest nieskończenie wiele. Należy jednak pamiętać, że nie powinno się brać pod uwagę przypadków skrajnie nieprawdopodobnych, gdzie gen jest, dla przykładu, wielokrotnie duplikowany i tracony. Po wprowadzeniu tego typu ograniczeń możliwe jest otrzymanie skończonego zbioru możliwych scenariuszy ewolucyjnych, które zwane są semi-normalnymi.

1.4.1. Transformacje scenariuszy ewolucyjnych

Za podstawę do uzyskania zbioru scenariuszy semi-normalnych dla danego drzewa G może służyć uzyskane dzięki mapowaniu LCA drzewo uzgadniające, które w kolejnych krokach poddawane będzie ściśle określonym transformacjom:

Definicja 1.4.1 *TMOVE*.


Definicja 1.4.2 *CLOST*.

Stosując kombinacje podanych ruchów można wyselekcjonować takie scenariusze, które określą oczekiwany zbiór (Patrz rysunek ??).

1.4.2. Opis modeli

W pracy tej zajęto się podanymi modelami, które dopuszczają podane warunki:


1. Model PG [?]: Model ten dopuszcza tylko takie scenariusze, które zachowują minimalny koszt duplikacyjny. Oznacza to, że są to scenariusze osiągalne ze scenariusza LCA za pomocą transformacji TMOVE.
2. Model FHS [?]: Model ten dopuszcza każde możliwe przekształcenie scenariuszy ewolucyjnych, a ich koszt duplikacyjny może być większy. Oznacza to, że są to scenariusze osiągalne ze scenariusza LCA za pomocą transformacji TMOVE i CLOST.



Rysunek 1.5: Diagram redukcyjny obrazujący możliwość uzyskania scenariuszy semi-normalnych. Na dole rysunku znajduje się drzewo uzyskane za pomocą mapowania LCA. Model PG zawierać będzie tylko właśnie to drzewo, podczas gdy dla modelu FHS wszystkie drzewa obecne na diagramie są częścią zbioru scenariuszy semi-normalnych.

1.5. Koszt scenariuszy ewolucyjnych

Klasyczną miarą kosztu ewolucyjnego danego scenariusza jest liczba duplikacji potrzebnych do uzgodnienia drzewa genów i gatunków. Za pomocą tej wartości możliwe jest porównywanie poszczególnych scenariuszy. Problemem jest jednak odpowiednie klastrowanie duplikacji, które następują bezpośrednio po sobie. Zależnie od obranej metody klastrowania ich liczba na danym węźle drzewa gatunków może znacząco się różnić co ma znaczny wpływ na problematykę poszukiwania scenariuszy o najmniejszym koszcie ewolucyjnym.



Rysunek 1.6: Różne metody klastrowania na przykładzie drzewa genów (po lewej stronie) gdzie duplikacje zostały oznaczone jako niebieskie kwadraty. W klastrowaniu EC wszystkie duplikacje są klastrowane jako jeden epizod duplikacyjny. W klastrowaniu ME dzieci nie mogą znajdować się w tym samym klastrze co ojciec. W klastrowaniu GD każda duplikacja musi zostać opisana jako oddzielny klaster.

Problemem jest też ustalenie kosztu ewolucyjnego zbioru scenariuszy drzew genów \mathcal{G} w oparciu o drzewo gatunków S . Można powiedzieć, że dwa węzły duplikacyjne d_1 i d_2 z \mathcal{G} można klastrować razem (oznaczymy jako $d_1 \iff d_2$) jeśli wszystkie poniższe warunki są spełnione:

1. $L(d_1) = L(d_2)$,
2. d_1 i d_2 są obecne w tym samym drzewie DLS.

$MEScore(\mathcal{G}, S)$ to minimalna wielkość partycji zbioru wszystkich węzłów duplikacyjnych obecnych w scenariuszach tak, że każde dwie duplikacje z tej samej partycji można sklastrować razem.

Definicja 1.5.1 $MEScore(\mathcal{G}, S) = \min_{\cup P = Dup(\mathcal{G})} \{|P| : \forall A \in P \forall d_1, d_2 \in A d_1 \iff d_2\}$

gdzie $Dup(\mathcal{G})$ jest zbiorem wszystkich węzłów duplikacyjnych obecnych w \mathcal{G}

Rozdział 2

Heurystyka

2.1. Opis problemu

2.2. Opis algorytmu

Algorytm zakłada, że na wejściu dostępne są dane:

- Drzewa genów $G_1 \dots G_k$,
- m_i scenariuszy drzewa G_i opisanych jako wektory $v_{i1}, v_{i2} \dots v_{im}$ z wyliczonymi wartościami kosztu ewolucyjnego, mierzonego jako ilość duplikacji dla każdego węzła.

Istnieje wektor przybliżający rozwiązanie ME, który nazwijmy V^* i który pasuje do każdego scenariusza.

Jednym z takich wektorów jest wektor V_{max} , który na każdej współrzędnej x zawiera maksymalną wartość $v_{im}[x]$ dla każdego scenariusza m w każdym drzewie genów G_i . Oczywiście nie jest to rozwiązanie najlepsze, ponieważ jest one kosztowne, ale pasuje do każdego scenariusza.

Bazując na wyliczonym wektorze V_{max} heurystyka wylicza wektor V^* i w pętli poprawia go w następujący sposób:

- Obniż jedną z wartości w wektorze V^* ,
- Zaakceptuj w/w zmianę jeśli dla każdego drzewa genów istnieje scenariusz, który jest zgodny z takim wektorem epizodów,
- Zakończ działanie jeśli nie da się poprawić żadnej współrzędnej.

Wybór współrzędnej może, zależnie od potrzeby, może być dokonywany w inny sposób:

- od końca wektora (od korzenia),
- od początku (od liści),
- losowo.

2.3. Dokumentacja użytkowa i opis implementacji

Opisana heurystyka zaimplementowana została w języku Python w wersji 3.7.4 przy użyciu paradygmatu obiektowego, gdzie zbiór wszystkich scenariuszy dla wszystkich drzew, pojedynczy diagram redukcyjny otrzymany z jednego drzewa genów, a także pojedynczy scenariusz

stanowią oddzielne klasy. Fragment kodu można zobaczyć w dodatku A. Program pythonowy przyjmuje na wejściu listę plików w których zawarte są wyliczone scenariusze dla danego drzewa genów.

Algorytm ten, dla wygody użycia, został obudowany skryptem napisanym w języku bash, który pozwala na wyliczenie scenariuszy w modelu FHS i PG z wykorzystaniem programu DLSgen autorstwa dra hab. Pawła Góreckiego.[?] Program ten wylicza dla danego drzewa genów i drzewa gatunków scenariusze ewolucyjne, które wykorzystywane są jako dane wejściowe dla proponowanej heurystyki.

2.4. Testy algorytmu


Do sprawdzenia wyników wyliczanych przez proponowany algorytm użyty został program RME napisany przez dra Jarosława Paszka. Program ten korzystając z dostępnych metod algorytmicznych wylicza dokładne i najniższe możliwe wartości kosztu ewolucyjnego dla podanych modeli. [2]

Z powodu trudności w obliczeniu danych wejściowych dla heurystyki obecnie nie ma możliwości dla przetestowania algorytmów dla dużych zbiorów danych.


Ze względu na czytelność wykresów w dalszej części pracy we wszystkich testach uwzględniony został tylko losowy wybór współrzędnej. W trakcie testów okazało się również, że taki wybór prowadzi zawsze do najlepszych wyników.

2.4.1. Testy algorytmu na danych rzeczywistych

Zbiorem danych dla testu na danych rzeczywistych był zbiór Guigo zawierający 53 ukorzenione drzewa genów pochodzące od 16 eukariontów. Zbiór ten zawiera dwa drzewa gatunków S_1 i S_2 . [?]




(a) Drzewo S_1




(b) Drzewo S_2

Rysunek 2.1: Drzewa gatunków ze zbioru Guigo




(a) Test algorytmu dla modelu PG




(b) Test algorytmu dla modelu FHS

Rysunek 2.2: Testy algorytmu na danych rzeczywistych dla drzewa gatunków S_1



(a) Test algorytmu dla modelu PG




(b) Test algorytmu dla modelu FHS

Rysunek 2.3: Testy algorytmu na danych rzeczywistych dla drzewa gatunków S_2


Dla wszystkich przypadków algorytm przy losowym wyborze współrzędnych jest w stanie osiągnąć wyniki identyczne jak te wyliczone przez program RME.

2.4.2. Testy algorytmu na danych symulowanych

Dane dla testów syntetycznych zostały wygenerowane w sposób losowy jednak wielkość, struktura i ilość drzew genów zostały dopasowane do zbioru Guigo. Zbiory symulowane zawierają syntetyczne drzewo gatunków z 15 etykietami oraz losowo wygenerowane 48 ukorzenione drzewa genów oparte o etykiety obecne w drzewie gatunków. Przykładowe drzewa gatunków (w formie graficznej) i genów (w formie tekstowej) można znaleźć w dodatkach do pracy. Test został przeprowadzony dla 1000 losowych zestawów.



(a) Test algorytmu dla modelu PG



(b) Test algorytmu dla modelu FHS

Rysunek 2.4: Testy algorytmu na danych symulowanych. Przez różnicę rozumiany jest wynik odjęcia od wyliczeń otrzymanych przez program RME wyliczeń otrzymanych dzięki proponowanemu algorytmowi.

W obu przypadkach wyniki obliczeń heurystyki nie odbiegają znacząco od dokładnych wartości kosztu ewolucyjnego otrzymanych przez program RME. Za pomocą wykresu nie da się nawet dokładnie określić dla ilu zbiorów heurystyka nie wyliczyła prawdziwego, minimalnego kosztu.

Dla modelu PG tylko 4 zbiory z 1000 nie dały tego samego wyniku, a dla modelu FHS było to 17 zbiorów z 1000.

Rozdział 3

Podsumowanie

W pracy przedstawiono pierwszy i dosyć intuicyjny pomysł na ocenę scenariuszy ewolucyjnych pod kątem ilości duplikacji. Należy jednak wspomnieć, że samą ideę da się znacząco usprawnić i obniżyć złożoność obliczeniową być może nawet do poziomu liniowego.

Obecnie to właśnie krok w którym konieczne jest wyliczenie scenariuszy dla drzew genów jest krokiem najbardziej wymagającym czasowo i obliczeniowo. W związku z tym trudno mówić o czasie potrzebnym algorytmowi na własne obliczenia. Nie udało się zaobserwować, by algorytm kiedykolwiek potrzebował więcej niż jedną sekundę na wczytanie danych i więcej niż 0.3 sekundy na obliczenie drzewa o najmniejszym koszcie ewolucyjnym. Ponadto obecne wymaganie dotyczące danych wejściowych uniemożliwia przetestowanie algorytmu na danych bardziej złożonych niż zbiór Guigo.

Testy pokazują również, że opisany algorytm zwraca wyniki, które różnią się w bardzo niewielkim stopniu (o ile w ogóle) od rzeczywistego minimalnego kosztu ewolucyjnego, gdyż maksymalnie tylko dla 2,8% danych algorytm nie uzyskał najniższego możliwego wyniku. Maksymalna różnica jaką udało się zaobserwować wynosiła 1, co również nie jest dużą wartością. Może to jednak wynikać z dosyć niskiego kosztu ewolucyjnego danych zbiorów, który wynosił maksymalnie 9 (średni koszt ewolucyjny to 6,1) dla modelu PG i 7 (średni koszt ewolucyjny to 4,5) dla modelu FHS. Widać jednak, że proponowany algorytm wymaga kolejnych, bardziej rozbudowanych testów.

3.1. Perspektywy rozwoju

Trudno przewidzieć wszystkie możliwości rozwoju algorytmu, ale te bardziej oczywiste można wskazać już teraz. Są to:

- Uniezależnienie algorytmu od kroku w którym wyliczane są scenariusze i klastrowanie duplikacji bezpośrednio na podstawie drzew genów.
- Uliniowanie algorytmu.

Szczególnie punkt pierwszy proponowanych usprawnień jest kluczowy dla dalszego rozwoju heurystyki, ponieważ pozwoli on na używanie i dotestowanie go na danych dużo bardziej skomplikowanych i bardziej przystających do obecnych problemów niż zbiór Guigo.

3.2. Perspektywy wykorzystania

Podstawową zaletą przedstawionej heurystyki jest jej elastyczność. Ocena scenariuszy nie zależy od obranego modelu, a obecnie wydaje się, że same obliczenia nie są obciążone dużym

błędem. Kolejną niewątpliwą zaletą jest fakt, że w istocie również struktura drzewa nie ma dla algorytmu dużego znaczenia. Obecnie powoli odchodzi się od drzewa binarnego jako metody przedstawienia historii ewolucji i algorytm jest na taką zmianę gotowy. Z punktu widzenia algorytmu drzewa są tablicą zawierającą ilość klastrow duplikacyjnych dla danego węzła, a które umieszczone są w niej w porządku prefiksowym, co zapewnia możliwość wykorzystania algorytmu nie tylko dla drzew binarnych. Algorytm funkcjonuje obecnie jednak w dosyć prymitywnej formie i wymaga wzmożonej i dokładnej pracy, ale sam algorytm rokuje niezwykle pozytywnie.

Dodatek A

Pętla programu zapisana w języku Python wykonywana dla losowego wybierania indeksów

```
max_trees = []
for scenario in self:
    all_dup_pref = [tree.duplication_prefix for tree n scenario]
    max_trees.append(self.rate_scenario(all_dup_pref))
max_tree = self.rate_scenario(max_trees)

if select_type == "random":

    index_list = [x for x in range(len(max_tree)) if x != 0]


    while index_list:
        index_list_position = random.randint(0, len(index_list) - 1)
        index = index_list[index_list_position]

        max_tree_temp = max_tree[:]
        max_tree_temp[index] -= 1


        for scenario in self:
            for tree in scenario:
                for i in range(len(tree.duplication_prefix)):
                    if max_tree_temp[i] - tree.duplication_prefix[i] < 0:
                        break
                else:
                    break
            else:
                index_list.pop(index_list_position)
                break
        else:
            max_tree = max_tree_temp
    return max_tree, sum(max_tree)
```


Dodatek B

Przykładowe drzewa gatunków dla danych syntetycznych



Rysunek B.1: Drzewo gatunków S_1



Rysunek B.2: Drzewo gatunków S_2

Dodatek C

Przykładowe drzewa genów dla danych syntetycznych

Format tekstowy:

((b,l),h)
((a,k),b)
((i,k),a)
((l,b),o)
(h,(j,o))
(b,(i,c))
(b,(m,j))
((m,a),b)
((g,m),f)
((a,l),k)
(o,(j,h))
((k,d),i)
(e,(c,o))
(f,(a,h))
(j,(k,d))
((k,e),c)
(j,(e,b))
((i,n),l)
(f,(b,h))
(c,(k,g))
((l,o),j)
((a,f),d)
((f,h),j)
(h,(d,n))
((b,j),i)
((a,e),(g,l))
((b,c),(n,o))
(m,((j,h),d))
((e,(f,g)),a)
(((m,d),g),a)
((h,l),(n,b))
((d,(b,a)),k)

$((k,n),c),m)$
 $((d,c),b),(j,a))$
 $(c,(l,(g,j)),k))$
 $((h,g),(a,e)),l)$
 $((o,(f,e)),(j,h))$
 $((g,l),((c,m),n))$
 $((e,(f,(j,o))),k)$
 $(f,(a,((n,h),(b,c))))$
 $((a,(o,h)),((e,i),n))$
 $((e,d),((a,b),(n,g)))$
 $((m,(d,b)),j),(f,e))$
 $(l,h),(((a,j),((m,g),f)),e))$
 $((n,(i,e)),(((a,k),f),(l,b)))$
 $((j,e),(i,((a,(k,(l,d))),n)))$
 $((((f,k),(b,(o,e))),((g,n),j)),m)$
 $(h,((b,(m,f)),((c,j),(a,(k,l)))))$

Bibliografia

- [1] Wszystkie obrazy wygenerowane zostały za pomocą serwisu <http://gsevol.azor.mimuw.edu.pl>
- [2] Jarosław Paszek, Paweł Górecki <https://www.mimuw.edu.pl/~jpaszek/rme.html>
- [3] *DLS-trees: a model of evolutionary scenarios*, *Theoretical Computer Science* 359 (1-3) 2006, s. 378–399. zobacz